

Добро пожаловать в Aither!

Версия: CB-WEBUI-01-R1 **Дата:** 25 июля 2026

Содержание

1. [Что такое Aither?](#)
 2. [Зачем проводится Closed Beta?](#)
 3. [Что тестируется?](#)
 4. [___ Новое: Web UI](#)
 5. [Что ожидается от вас?](#)
 6. [Что НЕ следует делать?](#)
 7. [Как начать?](#)
-

Что такое Aither?

Aither — это внутренняя платформа для работы с AI-моделями (LLM). Она предоставляет доступ к большим языковым моделям через **Web UI** (основной способ) и стандартный API, совместимый с OpenAI.

Проще говоря: вы общаетесь с AI-моделью в браузере или через API. Вы можете: - Вести диалог с моделью в браузере (**Web UI — основной интерфейс**) - Генерировать текст (completion) - Использовать разные модели для разных задач - Создавать API-ключи для автоматизации и AI-агентов

Зачем проводится Closed Beta?

Перед тем как открыть доступ для всех, мы проводим **закрытое тестирование** с ограниченной группой пользователей (до 5 человек).

Цели тестирования: 1. Проверить стабильность системы под реальной нагрузкой 2. Протестировать Web UI на удобство и отзывчивость 3. Найти ошибки и неудобства 4. Понять, как пользователи реально используют систему 5. Собрать обратную связь для улучшения

Что тестируется?

- **Web UI:** Авторизация, чат, управление API-ключами, переключение моделей

- **API:** Доступность, скорость, корректность ответов
 - **Модели:** Качество ответов qwen-14b (чат) и qwen-32b-base (completion)
 - **Аутентификация:** Работа учётных записей (Web UI) и API-ключей (`athr_` - токенов)
 - **Документация:** Понятность и полнота инструкций
 - **Две зоны доступа:** Internet и Test Zone
 - **Инфраструктура:** Стабильность под нагрузкой
-

Новое: Web UI

Aither теперь имеет Web UI — это основной интерфейс!

Зона	URL	Доступ
Internet	<code>https://fb1.spb.ru:443/</code>	Открытый, HTTPS (Let's Encrypt)
Test Zone	<code>http://10.129.13.78:30080/</code>	Внутренняя сеть / VPN

Возможности Web UI: - **Чат** — общение с моделями в браузере - **API Ключи** — создание и управление токенами - **Панель управления** — статус системы и моделей - **Две зоны** — Internet и Test Zone (автоопределение)

API также доступен для разработчиков — см. API GUIDE.

Что ожидается от вас?

Как участник Closed Beta, вы:

1. **Получаете учётную запись Web UI** от владельца проекта
 2. **Изучаете документацию** (этот пакет)
 3. **Выполняете тестовые задания** из TEST ASSIGNMENT (все через Web UI)
 4. **Сообщаете о проблемах** через BUG REPORT TEMPLATE
 5. **Заполняете обратную связь** через FEEDBACK FORM
 6. **Используете систему в реальных задачах** (по желанию)
-

Что НЕ следует делать?

1. **Не передавайте свои учётные данные** (логин/пароль) другим людям
2. **Не публикуйте API-ключи** в открытых источниках (GitHub, чаты, форумы)
3. **Не пытайтесь взломать систему** (тестирование безопасности НЕ входит в ваши задачи)
4. **Не нагружайте систему намеренно** (стресс-тесты проводит команда)
5. **Не используйте чужие учётные записи или API-ключи**

6. **Не передавайте конфиденциальные данные** через Web UI или API (тестовая среда!)
 7. **Не ожидайте Production-надёжности** — это Beta, возможны сбои
-

Как начать?

1. Откройте **Web UI** — `https://fb1.spb.ru:443/`
2. Перейдите к QUICK START — ваш первый диалог за 5 минут
3. Изучите WEB UI GUIDE — полные возможности интерфейса
4. Выполните TEST ASSIGNMENT — обязательные задания

Добро пожаловать в команду тестирования Aither!

Aither — Быстрый старт

Время на выполнение: 5 минут **Что нужно:** учётная запись Web UI (получите у администратора)

Содержание

- [Web UI \(рекомендуется\)](#)
 - [Для разработчиков: curl / Python / PowerShell](#)
-

Рекомендуемый способ — Web UI

Шаг 1: Откройте Web UI

Откройте браузер и перейдите:

Internet: `https://fb1.spb.ru:443/` **Test Zone:** `http://10.129.13.78:30080/`

Сертификат HTTPS — доверенный (Let's Encrypt). Предупреждений браузера быть не должно.

Шаг 2: Войдите

Введите имя пользователя и пароль, полученные от администратора.

Шаг 3: Откройте Чат

Нажмите **Чат** в верхнем меню.

Шаг 4: Выберите модель

В выпадающем списке выберите: - **qwen-14b (Чат)** — для диалогов - **qwen-32b-base (Базовая)** — для продолжения текста

Шаг 5: Отправьте сообщение

Введите текст и нажмите **Enter**.

Шаг 6: Получите ответ

Модель ответит в чате. Используйте кнопку **Копировать** для сохранения ответа.

Шаг 7: Проверьте обе модели

Переключитесь на другую модель и отправьте ещё один запрос.

Вы освоили Aither! Переходите к тестовым заданиям.

Для разработчиков: curl / Python / PowerShell

Шаг 1: Проверка подключения

Откройте терминал (командную строку) и выполните:

curl (Linux / macOS / WSL)

```
curl https://fb1.spb.ru:443/v1/models \  
-H "Authorization: Bearer ВАШ_API_КЛЮЧ"
```

PowerShell (Windows)

```
Invoke-RestMethod -Uri "https://fb1.spb.ru:443/v1/models" \  
-Headers @{"Authorization"="Bearer ВАШ_API_КЛЮЧ"}
```

Python

```
import requests  
response = requests.get(  
    "https://fb1.spb.ru:443/v1/models",  
    headers={"Authorization": "Bearer ВАШ_API_КЛЮЧ"}  
)  
print(response.json())
```

Ожидаемый ответ:

```
{  
  "object": "list",  
  "data": [  
    {"id": "qwen-14b", "object": "model", "owned_by": "aither"},  
  ]  
}
```

```
{
  "id": "qwen-32b-base", "object": "model", "owned_by": "aither"
}
```

Если получили ошибку `401` — проверьте API-ключ. Если таймаут — проверьте подключение к интернету. **API-ключи имеют префикс `athr_`**. Создать ключ можно в Web UI: [API Ключи](#) → Создать.

Шаг 2: Список моделей

Вы уже получили список моделей на шаге 1. Система предоставляет **две модели**:

Модель	Тип	Для чего
qwen-14b	Чат (instruct)	Диалоги, вопросы-ответы
qwen-32b-base	Базовая (completion)	Продолжение текста

Шаг 3: Первый запрос к 14B (чат)

curl

```
curl https://fb1.spb.ru:443/v1/chat/completions \
-H "Authorization: Bearer ВАШ_API_КЛЮЧ" \
-H "Content-Type: application/json" \
-d '{
  "model": "qwen-14b",
  "messages": [{"role": "user", "content": "Привет! Расскажи, что ты умеешь."}],
  "max_tokens": 200
}'
```

Python

```
import requests
response = requests.post(
    "https://fb1.spb.ru:443/v1/chat/completions",
    headers={"Authorization": "Bearer ВАШ_API_КЛЮЧ", "Content-Type": "application/json"},
    json={
        "model": "qwen-14b",
        "messages": [{"role": "user", "content": "Привет! Расскажи, что ты умеешь."}],
        "max_tokens": 200
    }
)
print(response.json()["choices"][0]["message"]["content"])
```

Ожидаемый ответ: Осмысленный текст на русском языке.

Шаг 4: Запрос к 32B (completion)

Модель 32B — базовая, она продолжает текст, а не ведёт диалог.

curl

```
curl https://fb1.spb.ru:443/v1/chat/completions \
-H "Authorization: Bearer БАШ_API_КЛЮЧ" \
-H "Content-Type: application/json" \
-d '{
  "model": "qwen-32b-base",
  "messages": [{"role": "user", "content": "Продолжи: Однажды в студёную зимнюю пору"}],
  "max_tokens": 100
}'
```

Python

```
response = requests.post(
    "https://fb1.spb.ru:443/v1/chat/completions",
    headers={"Authorization": "Bearer БАШ_API_КЛЮЧ", "Content-Type": "application/json"},
    json={
        "model": "qwen-32b-base",
        "messages": [{"role": "user", "content": "Продолжи: Однажды в студёную зимнюю пору"}],
        "max_tokens": 100
    }
)
print(response.json()["choices"][0]["message"]["content"])
```

Важно: 32B — базовая модель. Ответ может быть не в формате диалога. Это нормально.

Что дальше?

- **Вы выполнили первый запрос!** Система работает.
- **Web UI** — основной интерфейс. Откройте <https://fb1.spb.ru:443/>.
- Переходите к WEB UI GUIDE — полное описание Web UI.
- Выполните TEST ASSIGNMENT — обязательные задания.
- Создайте API-ключ для автоматизации: API KEY USER GUIDE.
- Если что-то не работает — заполните BUG REPORT.

Aither — Руководство пользователя

Версия: CB-WEBUI-01-R1 · Дата: 25 июля 2026

Содержание

- 1. [Назначение системы](#)
- 2. [Способы доступа](#)
- 3. [Web UI — основной интерфейс](#)
- 4. [Чат с моделями через Web UI](#)
- 5. [Управление API-ключами через Web UI](#)
- 6. [API-доступ \(для разработчиков\)](#)
- 7. [Поддерживаемые модели](#)
- 8. [Поддерживаемые сценарии](#)
- 9. [Неподдерживаемые сценарии](#)
- 10. [Аутентификация](#)
- 11. [Формат запросов и ответов \(API\)](#)
- 12. [Рекомендации](#)
- 13. [Коды ошибок](#)

Назначение системы

Aither — это платформа для работы с большими языковыми моделями (LLM) через **Web UI** (основной способ) и OpenAI-совместимый API.

Основные применения: - Диалоги и вопросно-ответные системы - Генерация и продолжение текста - Помощь в написании кода - Перевод текста - Создание резюме и аннотаций - Подключение AI-агентов через API-токены

Способы доступа

Способ	URL	Для кого
Web UI	<code>https://fb1.spb.ru:443/</code>	Все пользователи (основной)
API	<code>https://fb1.spb.ru:443</code> (базовый URL)	Разработчики, автоматизация

Способ	URL	Для кого
Test Zone	<code>http://10.129.13.78:30080/</code>	Внутренняя сеть / VPN

Web UI — рекомендуемый способ. API — для автоматизации и AI-агентов.

Web UI — основной интерфейс

Доступ

Откройте браузер и перейдите по адресу: - **Internet:** `https://fb1.spb.ru:443/` (HTTPS, доверенный сертификат Let's Encrypt) - **Test Zone:** `http://10.129.13.78:30080/` (HTTP, внутренняя сеть)

Вход

Используйте **имя пользователя** и **пароль**, выданные администратором.

Панель управления

После входа отображается: - **Аккаунт:** имя пользователя и роль - **Система:** версия и статус (Работает / Деградация) - **Модели:** список доступных моделей - **Зона:** Internet или Test Zone (автоопределение) - **Быстрые действия:** чат, ключи, документация

Основные разделы

Раздел	Описание
Чат	Диалог с моделями в реальном времени
API Ключи	Создание/просмотр/отзыв API-токенов
Панель	Статус системы и моделей

Чат с моделями через Web UI

Выбор модели

В верхней части страницы — выпадающий список моделей:

Модель	Тип	Описание
qwen-14b	Чат	Для диалогов, вопросов-ответов, инструкций
qwen-32b-base	Базовая	Для продолжения текста

Параметры

В интерфейсе можно настроить: - **max_tokens** — максимальная длина ответа (по умолчанию: 2048) - **temperature** — «креативность» ответа (0.0 = точно, 1.0+ = творчески)

Отправка сообщения

1. Выберите модель
2. Введите сообщение
3. Нажмите **Enter** или ► Отправить
4. Дождитесь ответа (индикатор загрузки)

Действия с ответом

- **Копировать** — копирует ответ модели
- **Очистить** — очищает историю диалога

Управление API-ключами через Web UI

Перейдите в раздел **API Ключи:**

Создание ключа

1. Нажмите «+ Создать новый ключ»
2. Введите название (например, «Мой проект»)
3. Выберите модели: обе / только 14B / только 32B
4. Нажмите «Создать»
5. **Скопируйте полный ключ!** Он показывается только один раз.

Формат ключа: `athr_...` (Bearer-токен)

Отзыв ключа

1. Найдите ключ в таблице
2. Нажмите «Отозвать»
3. Подтвердите действие

Отозванный ключ немедленно перестаёт работать.

Подробнее: API KEY USER GUIDE.

API-доступ (для разработчиков)

Базовый URL: `https://fb1.spb.ru:443`

Аутентификация: `Authorization: Bearer ВАШ_API_КЛЮЧ`

API-ключ создаётся в Web UI (раздел API Ключи). Префикс: `athr_`.
HTTPS с доверенным сертификатом Let's Encrypt. Флаг `-k` не требуется.

Поддерживаемые модели

qwen-14b (рекомендуемая)

Параметр	Значение
ID модели	<code>qwen-14b</code>
Тип	Instruct (чат-модель)
Контекст	4096 токенов
Языки	Русский, английский, китайский
Для чего	Диалоги, ответы на вопросы, написание текстов

qwen-32b-base

Параметр	Значение
ID модели	<code>qwen-32b-base</code>
Тип	Base (completion)
Контекст	4096 токенов
Языки	Русский, английский, китайский
Для чего	Продолжение текста, генерация
Важно	Не оптимизирована для диалогов. Ответы в формате completion.

Поддерживаемые сценарии

Сценарий 1: Диалог с моделью (Web UI)

Откройте Чат, выберите **qwen-14b**, задавайте вопросы. Поддерживается история диалога в рамках сессии.

Сценарий 2: Диалог с моделью (API)

```
POST /v1/chat/completions
Модель: qwen-14b
```

Сценарий 3: Написание текста

Попросите модель написать письмо, статью, пост.

```
Модель: qwen-14b
Пример: "Напиши официальное письмо о переносе встречи"
```

Сценарий 4: Помощь с кодом

```
Модель: qwen-14b
Пример: "Напиши функцию на Python для сортировки списка словарей по ключу"
```

Сценарий 5: Перевод текста

```
Модель: qwen-14b
Пример: "Переведи на английский: Добро пожаловать в Aither"
```

Сценарий 6: Резюме текста

```
Модель: qwen-14b
Пример: "Сделай краткое резюме следующего текста: [текст]"
```

Сценарий 7: Продолжение текста

```
Модель: qwen-32b-base
Пример: "Продолжи: Искусственный интеллект — это..."
```

Сценарий 8: Создание API-ключа для AI-агента

Через Web UI: API Ключи → Создать. Подробнее: AI AGENT CONNECTION PRIMER.

Неподдерживаемые сценарии

Сценарий 1: Многошаговые диалоги с памятью через API

×

Система не сохраняет историю между запросами. Каждый API-запрос — новый.

Обходной путь: Передавайте историю в `messages` самостоятельно, либо используйте Web UI (история сохраняется в рамках сессии).

×

Сценарий 2: Потокковая передача (streaming)

`stream: true` не поддерживается. Ответ приходит целиком.

×

Сценарий 3: Вызов функций (function calling)

Модель не может вызывать внешние функции или API.

×

Сценарий 4: Загрузка файлов

API не поддерживает загрузку файлов. Только текст.

Сценарий 5: Тонкая настройка модели

Модели предоставляются «как есть». Тонкая настройка недоступна.

Аутентификация

Web UI

- Логин/пароль (выдаются администратором)
- Сессия сохраняется до выхода

API

Каждый запрос должен содержать заголовок:

```
Authorization: Bearer ***
```

API-ключ создаётся в Web UI или выдаётся администратором.

Формат ключа: `athr_<префикс>_<секретная часть>`

Без ключа — HTTP 401 . **Неверный ключ** — HTTP 401 . **Просроченный/отозванный ключ** — HTTP 401 .

Подробнее в SECURITY RULES и API KEY USER GUIDE.

Формат запросов и ответов (API)

Запрос (chat completions)

```
{
  "model": "qwen-14b",
  "messages": [
    {"role": "user", "content": "Ваш вопрос"}
  ],
  "max_tokens": 200
}
```

Поле	Тип	Обязательно	Описание
<code>model</code>	string	Да	ID модели (<code>qwen-14b</code> или <code>qwen-32b-base</code>)
<code>messages</code>	array	Да	Список сообщений. Каждое: <code>{"role": "user", "content": "..."} </code>
<code>max_tokens</code>	integer	Нет	Максимальное количество токенов в ответе (по умолчанию 2048)
<code>temperature</code>	float	Нет	«Креативность» (0.0–2.0, по умолчанию 0.7)

Ответ

```
{
  "id": "chatcmpl-...",
  "object": "chat.completion",
  "model": "qwen-14b",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "Текст ответа модели"
    },
  },
  "finish_reason": "stop"
```

```
}],  
"usage": {  
  "prompt_tokens": 30,  
  "completion_tokens": 100,  
  "total_tokens": 130  
}  
}
```

Рекомендации

1. **Используйте Web UI** для повседневной работы — это основной интерфейс.
2. **API** — для автоматизации и подключения AI-агентов.
3. **Для диалогов используйте qwen-14b** — она оптимизирована для общения.
4. **Для продолжения текста — qwen-32b-base** — более мощная, но базовая модель.
5. **Не делайте больше 4 одновременных API-запросов** к 14B — запросы встают в очередь.
6. **Делайте паузы между API-запросами** при интенсивном использовании.
7. **Проверяйте finish_reason** в ответе API: "stop" — успешно, "length" — ответ обрезан.
8. **Сохраняйте ID запроса** (id в ответе API) — пригодится для баг-репортов.
9. **Создавайте API-ключи в Web UI** — раздел API Ключи.

Коды ошибок

Код	Описание	Что делать
200	Успех	Всё работает
401	Неверный или отсутствующий ключ/сессия	Проверьте ключ (формат: athr_...) или войдите заново
404	Модель не найдена	Проверьте model в запросе. Доступны: qwen-14b , qwen-32b-base
422	Неверный формат запроса	Проверьте JSON: обязательны model и messages
429	Слишком много запросов	Подождите минуту, лимит: 300/мин
500	Внутренняя ошибка сервера	Сообщите через BUG REPORT
504	Таймаут шлюза	Модель не успела ответить. Повторите позже

Связанные документы

- QUICK START — быстрый старт
- WEB UI GUIDE — полное руководство по Web UI
- API GUIDE — детальное описание API
- API KEY USER GUIDE — управление ключами
- DUAL ZONE ACCESS GUIDE — Internet vs Test Zone
- FAQ — ответы на частые вопросы
- KNOWN LIMITATIONS — известные ограничения

Aither — Руководство по API

Версия: CB-WEBUI-01-R1 · Дата: 25 июля 2026

Содержание

- 1. [Общая информация](#)
- 2. [Аутентификация](#)
- 3. [Создание API-ключа](#)
- 4. [GET /v1/models — Список моделей](#)
- 5. [POST /v1/chat/completions — Чат и completion](#)
- 6. [Коды ответов](#)
- 7. [Ограничения](#)
- 8. [Примеры на разных языках](#)

Общая информация

Параметр	Значение
Базовый URL	https://fb1.spb.ru:443
Формат данных	JSON
Метод аутентификации	Bearer token (API Key)
Content-Type	application/json
TLS	Доверенный сертификат Let's Encrypt (флаг -k не требуется)

Аутентификация

Каждый запрос должен содержать заголовок:

```
Authorization: Bearer ***
```

Формат ключа:

```
athr_<префикс>_<секретная_часть>
```

API-ключи создаются через **Web UI** (раздел **API Ключи**) или выдаются администратором.

Пример заголовка в curl:

```
-H "Authorization: Bearer athr_..."
```

Пример в Python:

```
headers = {"Authorization": "Bearer athr_..."}
```

API-ключ чувствителен к регистру. Не добавляйте лишних пробелов.

Создание API-ключа

API-ключи создаются через **Web UI** — это основной способ:

В Web UI

1. Войдите в Web UI: `https://fb1.spb.ru:443/`
2. Перейдите в раздел **API Ключи**
3. Нажмите «+ **Создать новый ключ**»
4. Введите название ключа
5. Выберите доступные модели: обе / только 14B / только 32B
6. Нажмите «**Создать**»
7. **Скопируйте полный ключ немедленно!** Он отображается только один раз.

Через BFF API

```
# Создание токена через BFF
curl https://fb1.spb.ru:443/api/v1/tokens \
  -H "Authorization: Bearer ВАШ_API_КЛЮЧ" \
  -H "Content-Type: application/json" \
  -d '{"name": "Мой токен", "models": ["qwen-14b", "qwen-32b-base"]}'
```

Отзыв ключа

В Web UI: найдите ключ в таблице → нажмите «**Отозвать**» → подтвердите.

Через BFF API:

```
curl -X DELETE https://fb1.spb.ru:443/api/v1/tokens/athr_XXXX \  
-H "Authorization: Bearer ВАШ_API_КЛЮЧ"
```

Подробнее: API KEY USER GUIDE.

GET /v1/models — Список моделей

Возвращает список доступных моделей.

Запрос

```
curl https://fb1.spb.ru:443/v1/models \  
-H "Authorization: Bearer ВАШ_API_КЛЮЧ"
```

Ответ (HTTP 200)

```
{  
  "object": "list",  
  "data": [  
    {  
      "id": "qwen-14b",  
      "object": "model",  
      "created": 1784759438,  
      "owned_by": "aither"  
    },  
    {  
      "id": "qwen-32b-base",  
      "object": "model",  
      "created": 1784759438,  
      "owned_by": "aither"  
    }  
  ]  
}
```

Без аутентификации (HTTP 401)

```
{"detail": "Valid API Key required (format: athr_...)"}"
```

POST /v1/chat/completions — Чат и Completion

Основной эндпоинт для взаимодействия с моделями.

Параметры запроса

Параметр	Тип	Обязательно	Описание
<code>model</code>	string	Да	ID модели: <code>qwen-14b</code> или <code>qwen-32b-base</code>
<code>messages</code>	array	Да	Список сообщений
<code>max_tokens</code>	integer	Нет	Макс. токенов в ответе (по умолчанию: 2048)
<code>temperature</code>	float	Нет	Креативность: 0.0–2.0 (по умолчанию: 0.7)

Сообщение (message)

```
{"role": "user", "content": "Текст сообщения"}
```

Роли: `user` (пользователь), `assistant` (модель), `system` (системная инструкция).

Параметры ответа

Поле	Тип	Описание
<code>id</code>	string	Уникальный ID запроса
<code>object</code>	string	<code>"chat.completion"</code>
<code>model</code>	string	Используемая модель
<code>choices[0].message.role</code>	string	<code>"assistant"</code>
<code>choices[0].message.content</code>	string	Текст ответа
<code>choices[0].finish_reason</code>	string	<code>"stop"</code> (успех) или <code>"length"</code> (обрезано)
<code>usage.prompt_tokens</code>	integer	Токенов в запросе
<code>usage.completion_tokens</code>	integer	Токенов в ответе

Поле	Тип	Описание
<code>usage.total_tokens</code>	integer	Всего токенов

Коды ответов

Код	Значение	Действие
200	Успех	Ответ получен
401	Ошибка аутентификации	Проверить API-ключ (формат: <code>athr_...</code>)
404	Модель не найдена	Проверить <code>model</code>
422	Неверный формат	Проверить JSON
429	Rate limit	Подождать минуту
500	Ошибка сервера	Повторить позже, сообщить
504	Таймаут	Модель не ответила вовремя

Ограничения (Rate Limiting)

Параметр	Значение
Лимит запросов	300 запросов/минуту
Burst	20 запросов
Одновременные (14B)	~4 (очередь GPU)

При превышении лимита: **HTTP 429**.

Примеры на разных языках

curl (Linux / macOS)

```
# Список моделей
curl https://fb1.spb.ru:443/v1/models \
  -H "Authorization: Bearer ВАШ_API_КЛЮЧ"
```

```
# Чат с 14B
curl https://fb1.spb.ru:443/v1/chat/completions \
  -H "Authorization: Bearer БАШ_API_КЛЮЧ" \
  -H "Content-Type: application/json" \
  -d '{"model": "qwen-14b", "messages": [{"role": "user", "content": "Привет!"}], "max_tokens": 100}'

# Completion с 32B
curl https://fb1.spb.ru:443/v1/chat/completions \
  -H "Authorization: Bearer БАШ_API_КЛЮЧ" \
  -H "Content-Type: application/json" \
  -d '{"model": "qwen-32b-base", "messages": [{"role": "user", "content": "Продолжи: В начале было"}]'

# Создание токена через BFF
curl https://fb1.spb.ru:443/api/v1/tokens \
  -H "Authorization: Bearer БАШ_API_КЛЮЧ" \
  -H "Content-Type: application/json" \
  -d '{"name": "Мой токен", "models": ["qwen-14b", "qwen-32b-base"]}'

# Отзыв токена
curl -X DELETE https://fb1.spb.ru:443/api/v1/tokens/athr_XXXX \
  -H "Authorization: Bearer БАШ_API_КЛЮЧ"
```

Python

```
import requests

KEY = "athr_..."
BASE = "https://fb1.spb.ru:443"
HEADERS = {"Authorization": f"Bearer {KEY}", "Content-Type": "application/json"}

# Список моделей
r = requests.get(f"{BASE}/v1/models", headers=HEADERS)
print("Модели:", [m["id"] for m in r.json()["data"]])

# Чат с 14B
r = requests.post(f"{BASE}/v1/chat/completions", headers=HEADERS, json={
    "model": "qwen-14b",
    "messages": [{"role": "user", "content": "Привет! Как дела?"}],
    "max_tokens": 100
})
print("14B:", r.json()["choices"][0]["message"]["content"])

# Completion с 32B
r = requests.post(f"{BASE}/v1/chat/completions", headers=HEADERS, json={
    "model": "qwen-32b-base",
    "messages": [{"role": "user", "content": "Продолжи: Искусственный интеллект"}],
    "max_tokens": 50
})
print("32B:", r.json()["choices"][0]["message"]["content"])

# Создание токена
r = requests.post(f"{BASE}/api/v1/tokens", headers=HEADERS, json={
    "name": "Мой токен",
    "models": ["qwen-14b", "qwen-32b-base"]
})
```

```
print("Новый ключ:", r.json())

# Обработка ошибок
if r.status_code != 200:
    print(f"Ошибка {r.status_code}: {r.json().get('detail', r.text)}")
```

PowerShell (Windows)

```
$Key = "athr_..."
$Base = "https://fb1.spb.ru:443"
$headers = @{
    "Authorization" = "Bearer $Key"
    "Content-Type" = "application/json"
}

# Список моделей
$models = Invoke-RestMethod -Uri "$Base/v1/models" -Headers $headers
Write-Host "Модели: $($models.data.id -join ', ')"

# Чат с 14B
$body = @{
    model = "qwen-14b"
    messages = @(@{role="user"; content="Привет! Как дела?"})
    max_tokens = 100
} | ConvertTo-Json -Depth 3

$response = Invoke-RestMethod -Uri "$Base/v1/chat/completions" `
    -Method Post -Headers $headers -Body $body
Write-Host "14B: $($response.choices[0].message.content)"

# Completion с 32B
$body = @{
    model = "qwen-32b-base"
    messages = @(@{role="user"; content="Продолжи: Искусственный интеллект"})
    max_tokens = 50
} | ConvertTo-Json -Depth 3

$response = Invoke-RestMethod -Uri "$Base/v1/chat/completions" `
    -Method Post -Headers $headers -Body $body
Write-Host "32B: $($response.choices[0].message.content)"
```

Связанные документы

- [USER GUIDE](#) — полное руководство
- [WEB UI GUIDE](#) — основной интерфейс
- [QUICK START](#) — быстрый старт
- [API KEY USER GUIDE](#) — управление API-ключами
- [AI AGENT CONNECTION PRIMER](#) — подключение агентов
- [KNOWN LIMITATIONS](#) — ограничения
- [FAQ](#) — частые вопросы

Aither — Тестовые задания Closed Beta

Обязательно к выполнению всеми участниками.

Содержание

1. [Перед началом](#)
 2. [Задание 1: Получить список моделей](#)
 3. [Задание 2: 10 запросов к 14B](#)
 4. [Задание 3: 5 запросов к 32B](#)
 5. [Задание 4: Типовые сценарии](#)
 6. [Задание 5: Написать письмо](#)
 7. [Задание 6: Написать код](#)
 8. [Задание 7: Сделать резюме текста](#)
 9. [Задание 8: Перевод](#)
 10. [Задание 9: Работа с длинным текстом](#)
 11. [Задание 10: Сообщить о проблемах](#)
 12. [Чек-лист выполнения](#)
-

Перед началом

1. Получите персональный API-ключ у владельца проекта
 2. Убедитесь, что Quick Start работает (5 минут)
 3. Приготовьте терминал или Python-скрипт для запросов
-

Задание 1: Получить список моделей

Цель: Проверить доступность API и корректность аутентификации.

Выполните запрос:

```
curl -k https://fb1.spb.ru:443/v1/models \
-H "Authorization: Bearer ВАШ_API_КЛЮЧ"
```

Ожидаемый результат: - HTTP 200 - В ответе две модели: `qwen-14b` и `qwen-32b-base`

Отметьте: - [] Запрос выполнен успешно (HTTP 200) - [] Обе модели присутствуют в ответе

Задание 2: 10 запросов к 14B

Цель: Проверить стабильность чат-модели при повторных запросах.

Выполните **минимум 10** различных запросов к модели `qwen-14b` . Используйте разные темы:

№	Тема запроса	HTTP-код	Успешно?
1	Простой вопрос ("Как дела?")		
2	Фактический вопрос ("Столица Франции?")		
3	Запрос на русском (развёрнутый)		
4	Запрос на английском		
5	Математический вопрос ("2+2*2?")		
6	Логическая задача		
7	Креативное задание ("Придумай название")		
8	Технический вопрос ("Что такое Kubernetes?")		
9	Запрос с ограничением длины (max_tokens=10)		
10	Запрос без max_tokens		

Ожидаемый результат: Все 10 запросов — HTTP 200, осмысленные ответы.

Отметьте: Количество успешных запросов: ____/10

Задание 3: 5 запросов к 32B

Цель: Проверить работу базовой модели 32B.

Используйте модель `qwen-32b-base` . Дайте модели начало текста — она продолжит.

№	Начало текста	HTTP-код	Ответ осмысленный?
1	"Искусственный интеллект — это..."		
2	"В начале было слово, и слово..."		
3	"Основные принципы безопасности:"		
4	"Python — это язык программирования, который..."		
5	"The future of technology lies in..."		

Модель 32B базовая — ответы могут быть не в формате диалога. Это нормально.

Отметьте: Количество успешных запросов: ___/5

Задание 4: Типовые сценарии

Цель: Проверить систему на реалистичных задачах.

Выполните BCE сценарии:

- [] **Сценарий А: Вопрос-ответ.** Задайте вопрос, получите ответ, задайте уточняющий вопрос.
- [] **Сценарий В: Несуществующая модель.** Запросите модель `"nonexistent-model"`. Ожидается HTTP 404.
- [] **Сценарий С: Неверный ключ.** Используйте `"Bearer bad-key-123"`. Ожидается HTTP 401.
- [] **Сценарий D: Без ключа.** Уберите заголовок Authorization. Ожидается HTTP 401.
- [] **Сценарий Е: Неверный JSON.** Отправьте `{"bad": "json"}` — без `model`. Ожидается HTTP 422.

Задание 5: Написать письмо

Цель: Проверить способность модели генерировать структурированный текст.

Запрос к `qwen-14b` :

«Напиши официальное письмо клиенту о переносе сроков проекта на 2 недели. Укажи причину: дополнительные требования к тестированию. Тон: вежливый, профессиональный.»

Ожидаемый результат: - Структурированное письмо - Обращение, тело, заключение - Профессиональный тон

Отметьте: - ☐ Ответ структурирован - ☐ Тон соответствует запросу - ☐ Все ключевые пункты отражены

Задание 6: Написать код

Цель: Проверить способность модели генерировать код.

Запрос к qwen-14b :

«Напиши функцию на Python, которая принимает список словарей и возвращает отсортированный список по указанному ключу. Добавь обработку ошибок (отсутствие ключа, пустой список).»

Ожидаемый результат: - Корректный код на Python - Присутствует обработка ошибок - Код сопровождается пояснениями

Отметьте: - ☐ Код синтаксически корректен - ☐ Обработка ошибок присутствует - ☐ Пояснения понятны

Задание 7: Сделать резюме текста

Цель: Проверить способность суммаризации.

Возьмите текст из 3–5 абзацев (можно из новостей или документации) и попросите qwen-14b :

«Сделай краткое резюме следующего текста (3–4 предложения): [ВАШ ТЕКСТ]»

Ожидаемый результат: - Краткое резюме (3–4 предложения) - Сохранены ключевые мысли - Нет домысливания

Отметьте: - ☐ Резюме действительно краткое - ☐ Ключевые мысли сохранены - ☐ Нет выдуманных фактов

Задание 8: Перевод

Цель: Проверить качество перевода.

Запросы к qwen-14b :

№	Запрос	Результат
1	«Переведи на английский: Добро пожаловать в систему Aither. Мы рады, что вы присоединились к тестированию.»	
2	«Переведи на русский: Machine learning is a subset of artificial intelligence that enables systems to learn from data.»	
3	«Переведи на английский технический текст: Kubernetes — это платформа для оркестрации контейнеров, автоматизирующая развёртывание, масштабирование и управление.»	

Отметьте: - ☐ Перевод корректен - ☐ Технические термины переведены правильно

Задание 9: Работа с длинным текстом

Цель: Проверить обработку длинного контекста.

Отправьте сообщение длиной ~2000–3000 символов (например, статью или документацию) и попросите модель:

«Ответь на вопросы по тексту выше: 1) О чём этот текст? 2) Какие ключевые выводы?»

Ожидаемый результат: - Модель «понимает» контекст - Ответы релевантны содержанию - HTTP 200 (не 500/504)

Отметьте: - ☐ Запрос обработан (не таймаут) - ☐ Ответ соответствует содержанию - ☐ Модель не «потеряла» контекст

Задание 10: Сообщить о проблемах

Цель: Проверить процесс обратной связи.

Заполните: 1. BUG REPORT — для каждой найденной ошибки 2. FEEDBACK FORM — общая обратная связь

Даже если ошибок нет — заполните Feedback Form! Нам важно знать, что всё работает.

Чек-лист выполнения

Отметьте выполненные задания:

- | | | |
|---|-----|------------------|
| ☐ Задание 1: Список моделей | [] | |
| ☐ Задание 2: 10 запросов к 14B | [] | Успешно: ____/10 |
| ☐ Задание 3: 5 запросов к 32B | [] | Успешно: ____/5 |
| ☐ Задание 4: Типовые сценарии (A–E) | [] | |
| ☐ Задание 5: Написать письмо | [] | |
| ☐ Задание 6: Написать код | [] | |
| ☐ Задание 7: Резюме текста | [] | |
| ☐ Задание 8: Перевод | [] | |
| ☐ Задание 9: Длинный текст | [] | |
| ☐ Задание 10: Bug Report + Feedback Form | [] | |

Когда всё выполнено: передайте заполненные формы владельцу проекта.

Aither — Руководство по Web UI

Версия: Beta RC · CB-WEBUI-01

Содержание

1. [Доступ к Web UI](#)
 2. [Вход в систему](#)
 3. [Панель управления](#)
 4. [Чат с моделями](#)
 5. [Управление API-ключами](#)
 6. [Две зоны доступа](#)
 7. [Часто задаваемые вопросы](#)
-

Доступ к Web UI

Internet (публичный доступ)

```
https://fb1.spb.ru:443/
```

- Доступен из интернета
- HTTPS (самоподписанный сертификат — подтвердите исключение в браузере)
- Полный функционал: чат, API-ключи, статус

Test Zone (внутренняя сеть)

```
http://10.129.13.78:30080/
```

- Доступен только из внутренней сети / VPN
 - Тот же функционал, что и Internet
 - Зона отображается как **TEST ZONE** в интерфейсе
-

Вход в систему

1. Откройте Web UI в браузере
2. Введите **имя пользователя** и **пароль** (выдаются администратором)
3. Нажмите «**Войти**»

После входа вы увидите панель управления.

При ошибке входа: - Проверьте правильность учётных данных - Убедитесь, что используете актуальный URL - Обратитесь к администратору

Панель управления

После входа отображается:

- **Аккаунт:** ваше имя пользователя и роль
 - **Система:** версия и статус (Работает / Деградация)
 - **Модели:** список доступных моделей
 - **Зона:** Internet или Test Zone (автоопределение)
 - **Быстрые действия:** ссылки на чат, ключи, документацию
-

Чат с моделями

Выбор модели

В верхней части страницы чата — выпадающий список:

Модель	Тип	Описание
qwen-14b	Чат	Для диалогов, вопросов-ответов, инструкций
qwen-32b-base	Базовая	Для продолжения текста

Рядом с селектором отображается подсказка о типе модели.

Отправка сообщения

1. Выберите модель
2. Введите сообщение в поле ввода
3. Нажмите **Enter** или кнопку ► **Отправить**
4. Дождитесь ответа (индикатор загрузки)

Дополнительные возможности

- **Копировать** — копирует ответ модели
- **Очистить** — очищает историю диалога
- **max_tokens** — ограничение длины ответа
- **temperature** — «креативность» (0 = точно, 1 = творчески)

Особенности моделей

- **qwen-14b** оптимизирована для диалогов — используйте для общения
- **qwen-32b-base** базовая модель — дайте начало текста, она продолжит
- При смене модели контекст диалога сохраняется

Ошибки

Ситуация	Сообщение
Проблемы с авторизацией	«Ошибка авторизации. Войдите заново.»
Модель недоступна	«Модель или endpoint не найден.»
Превышен лимит	«Превышен лимит запросов. Подождите минуту.»
Таймаут	«Таймаут — модель не успела ответить.»
Ошибка сети	«Ошибка сети — проверьте подключение.»

Управление API-ключами

Страница **API Ключи** позволяет:

- Просматривать существующие ключи (префикс, статус, даты)
- Создавать новые ключи (с выбором моделей)
- Отзывать ключи

Создание ключа

1. Нажмите **«+ Создать новый ключ»**
2. Введите название ключа
3. Выберите модели (обе / 14B / 32B)
4. Нажмите **«Создать»**

Полный ключ показывается только один раз! Скопируйте его сразу.

Отзыв ключа

1. Найдите ключ в таблице
2. Нажмите **«Отозвать»**
3. Подтвердите действие

Отозванный ключ немедленно перестаёт работать.

Две зоны доступа

Aither предоставляет две точки доступа:

Зона	URL	Доступ
Internet	<code>https://fb1.spb.ru:443/</code>	Открытый
Test Zone	<code>http://10.129.13.78:30080/</code>	Внутренний / VPN

Интерфейс автоматически определяет зону и показывает:

- **INTERNET** (зелёный бейдж) — публичный доступ
- **TEST ZONE** (жёлтый бейдж) — тестовая сеть

API-ключи работают в обеих зонах. Один ключ — доступ везде.

Часто задаваемые вопросы

Как получить учётную запись?

Обратитесь к администратору проекта.

Почему сертификат недействителен?

Используется самоподписанный сертификат. В Production будет заменён на публичный.

Как подключить AI-агента?

Используйте API-ключ, созданный в Web UI. См. `16_AI_AGENT_CONNECTION_PRIMER.md`.

Чем отличается Internet от Test Zone?

Функционально — ничем. Test Zone доступна только из внутренней сети.

Почему 32B отвечает иначе?

Это базовая модель (не чат). Она продолжает текст, а не ведёт диалог.

Связанные документы

- QUICK START — быстрый старт через Web UI

- [API GUIDE](#) — для разработчиков
- [FAQ](#) — все вопросы
- [SECURITY RULES](#) — безопасность

Aither — Часто задаваемые вопросы (FAQ)

Содержание

- [Доступ и аутентификация](#)
 - [Модели](#)
 - [Запросы и ответы](#)
 - [Ошибки](#)
 - [Ограничения](#)
 - [Безопасность](#)
 - [Общие вопросы](#)
-

Доступ и аутентификация

1. Как получить API-ключ?

Обратитесь к владельцу проекта. Он выдаст вам персональный ключ формата `aither_XXXXXXX_...`.

2. Что делать, если я потерял API-ключ?

Немедленно сообщите владельцу проекта. Старый ключ будет отозван, выдан новый.

3. Можно ли использовать один ключ на нескольких компьютерах?

Да, ваш персональный ключ можно использовать с любого устройства. Но не передавайте его другим людям.

4. Как проверить, что ключ работает?

Выполните `GET /v1/models`. HTTP 200 = ключ работает. HTTP 401 = ключ неверный.

5. Что делать при ошибке 401?

Проверьте: - Правильно ли скопирован ключ (без лишних пробелов) - Формат заголовка: `Authorization: Bearer ВАШ_КЛЮЧ` - Не истёк ли ключ (сообщите владельцу)

Модели

6. Какие модели доступны?

Две модели: - `qwen-14b` — чат-модель, оптимизирована для диалогов - `qwen-32b-base` — базовая модель, для продолжения текста

7. Какую модель выбрать?

- Для диалогов, вопросов-ответов, инструкций → `qwen-14b`
- Для продолжения текста, генерации → `qwen-32b-base`

8. Почему 32B отвечает «не по-человечески»?

`qwen-32b-base` — базовая модель, она не обучена вести диалог. Она просто продолжает текст. Для диалогов используйте `qwen-14b`.

9. Есть ли другие модели?

На данный момент — только эти две. Новые модели могут быть добавлены в будущих версиях.

10. Какой максимальный размер запроса?

Контекстное окно — 4096 токенов. Это примерно 3000–3500 слов на русском языке.

Запросы и ответы

11. Как отправить запрос?

Самый простой способ — curl. См. QUICK START и API GUIDE.

12. Почему ответ обрезан?

Проверьте `finish_reason` в ответе: - `"stop"` — модель завершила ответ - `"length"` — ответ обрезан из-за ограничения `max_tokens`. Увеличьте `max_tokens`.

13. Можно ли вести многошаговый диалог?

Система не хранит историю. Чтобы продолжить диалог, передайте всю историю в массиве `messages` :

```
{
  "messages": [
    {"role": "user", "content": "Привет"},
    {"role": "assistant", "content": "Здравствуйте!"},
    {"role": "user", "content": "Как дела?"}
  ]
}
```

14. Как получить ответ в JSON?

Просто попросите модель в запросе: «Ответь в формате JSON». Модель сама структурирует ответ.

15. Какой формат даты и времени использовать?

Модель понимает стандартные форматы: `2026-07-25` , `25 июля 2026` , `July 25, 2026` .

16. Поддерживается ли Markdown в ответах?

Да, модель может форматировать ответы с помощью Markdown: заголовки, списки, код.

Ошибки

17. Что делать при HTTP 404?

Вы указали несуществующую модель. Доступны только `qwen-14b` и `qwen-32b-base` .

18. Что делать при HTTP 422?

Неверный формат запроса. Проверьте: - JSON корректен? - Поле `model` указано? - `messages` — массив с элементами?

19. Что делать при HTTP 429?

Вы превысили лимит запросов (300/мин). Подождите минуту.

20. Что делать при HTTP 500 или 504?

Внутренняя ошибка или таймаут. Повторите запрос позже. Если повторяется — заполните BUG REPORT.

21. Что делать, если запрос «завис» и нет ответа?

Подождите до 60 секунд. Если за это время ответ не пришёл — модель перегружена. Повторите позже.

22. Почему ответ содержит «мусор» или бессмысленный текст?

Возможно для `qwen-32b-base` (нормально для базовой модели). Для `qwen-14b` — сообщите через Bug Report.

Ограничения

23. Сколько запросов можно делать?

До 300 запросов в минуту, до ~4 одновременных на 14B.

24. Почему запросы идут медленно под нагрузкой?

14B использует GPU. При нескольких одновременных запросах они встают в очередь. Ожидание до 50 секунд при 4+ параллельных запросах — норма.

25. Сохраняются ли мои запросы?

Нет. Система не сохраняет историю диалогов. Каждый запрос независим.

26. Можно ли загружать файлы?

Нет. Только текст через API.

Безопасность

27. Нужно ли использовать HTTPS?

Да, система работает только через HTTPS (порт 443). Сертификат самоподписанный — используйте флаг `-k` в curl.

28. Кто видит мои запросы?

Ваши запросы видны только вам и администраторам системы. Не передавайте конфиденциальные данные.

29. Что делать, если я случайно опубликовал API-ключ?

Немедленно сообщите владельцу проекта для отзыва ключа.

30. Можно ли тестировать безопасность системы?

Нет. Тестирование безопасности не входит в задачи Closed Beta.

Общие вопросы

31. Сколько продлится Closed Beta?

По решению владельца проекта. Ориентировочно — несколько недель.

32. Будет ли система доступна после Beta?

Да, после успешного завершения Beta и Production Readiness система станет общедоступной внутри организации.

33. Могу ли я пригласить коллегу?

Нет. Состав участников определяется владельцем проекта. Максимум 5 человек.

34. Что делать, если я не могу выполнить задание?

Сообщите владельцу проекта. Это ценная информация — возможно, документацию нужно улучшить.

35. Как часто обновляется система?

По мере необходимости, с уведомлением участников. Критические обновления — немедленно.

Не нашли ответ?

Заполните BUG REPORT с пометкой «Вопрос по документации» или обратитесь к владельцу проекта.

Aither — Правила безопасности

Обязательно к соблюдению всеми участниками Closed Beta.

Содержание

1. [API-ключ — ваша ответственность](#)
 2. [Не передавайте ключ](#)
 3. [Не публикуйте ключ](#)
 4. [Не используйте чужие ключи](#)
 5. [Конфиденциальность запросов](#)
 6. [Сообщайте о подозрительной активности](#)
 7. [Что делать при компрометации ключа](#)
 8. [HTTPS и сертификаты](#)
 9. [Не тестируйте безопасность](#)
 10. [Запрещённый контент](#)
-

API-ключ — ваша ответственность

Ваш персональный API-ключ — это ваш пропуск в систему. Ключ:

- Привязан к вам лично
- Даёт доступ ко всем функциям API
- Позволяет идентифицировать ваши запросы

Вы несёте ответственность за все действия, выполненные с вашим ключом.

Не передавайте ключ

Запрещено передавать ваш API-ключ: - Коллегам - Другьям - В мессенджерах - По email

У каждого участника Closed Beta — **свой персональный ключ.**

Не публикуйте ключ

Запрещено публиковать ваш API-ключ: - В GitHub (коммиты, issues, gists) - В чатах (Telegram, Slack, Discord) - На форумах - В скриншотах - В блогах и социальных сетях

Если вы случайно опубликовали ключ — см. раздел «Что делать при компрометации».

Не используйте чужие ключи

Запрещено использовать API-ключ другого участника, даже с его разрешения.

Каждый ключ: - Отслеживается отдельно - Имеет свои лимиты - Может быть отозван независимо

Конфиденциальность запросов

Внимание: Aither находится в стадии Beta. Это означает:

- **Не передавайте конфиденциальные данные** через API (пароли, персональные данные, коммерческую тайну)
- **Не загружайте чувствительные документы** (система не шифрует запросы на уровне приложения)
- **Система логирует запросы** для отладки и мониторинга

Используйте Aither для тестовых, неконфиденциальных задач.

Сообщайте о подозрительной активности

Немедленно сообщите владельцу проекта, если:

- Ваш ключ перестал работать без причины
 - Вы получили ответ на запрос, который не делали
 - Вы заметили необычную активность (частые 401 на ваш ключ)
 - Кто-то попросил ваш ключ
-

Что делать при компрометации ключа

Если вы подозреваете, что ключ скомпрометирован:

1. Немедленно прекратите использование ключа
2. Сообщите владельцу проекта
3. Владелец отзовёт старый ключ и выдаст новый
4. Начинайте использовать новый ключ

Время реакции на компрометацию: немедленно.

HTTPS и сертификаты

- Система работает **только через HTTPS** (порт 443)
- Сертификат — **самоподписанный** (не от публичного CA)
- При использовании curl: добавляйте флаг `-k`
- При использовании Python: `verify=False`
- При использовании PowerShell: `-SkipCertificateCheck`

Не отключайте проверку сертификата в Production-окружении (после Beta).

Не тестируйте безопасность

Тестирование безопасности НЕ входит в задачи Closed Beta.

Не пытайтесь: - Сканировать порты - Подбирать API-ключи - Отправлять вредоносные запросы - Искать уязвимости - Обходить аутентификацию

Это может быть воспринято как атака и привести к блокировке.

Запрещённый контент

Не используйте Aither для генерации:

- Вредоносного кода
 - спама
 - Оскорбительного или дискриминационного контента
 - Материалов, нарушающих законодательство
-

Шпаргалка

Ситуация	Действие
Забыл ключ	Запросить у владельца
Опубликовал ключ	Срочно сообщить владельцу
Ключ перестал работать	Проверить формат, сообщить владельцу
Подозрительная активность	Сообщить владельцу
Чужой ключ	Не использовать

Соблюдение этих правил — залог безопасной и продуктивной Closed Beta.

Aither — Известные ограничения (Beta RC)

Версия: Beta Release Candidate (U1.4) · **Дата:** 25 июля 2026

Содержание

- [1. Функциональные ограничения](#)
 - [2. Ограничения моделей](#)
 - [3. Инфраструктурные ограничения](#)
 - [4. Ограничения Beta](#)
-

Функциональные ограничения

`/v1/completions` **недоступен**

Эндпоинт `POST /v1/completions` возвращает HTTP 404 на обоих портах (:443, :10443).

Workaround: Используйте `POST /v1/chat/completions` для обеих моделей: - `qwen-14b` — работает как чат - `qwen-32b-base` — работает как completion (через chat-интерфейс)

Статус: Запланировано к исправлению.

Нет потоковой передачи (streaming)

Параметр `"stream": true` не поддерживается. Ответ приходит целиком после завершения генерации.

Влияние: При длинных ответах пользователь ждёт весь ответ, не видя промежуточных результатов.

Нет истории диалогов

Система **stateless** — не сохраняет историю между запросами. Каждый запрос обрабатывается независимо.

Workaround: Передавайте историю в массиве `messages` самостоятельно:

```
{
  "messages": [
    {"role": "user", "content": "Вопрос 1"},
    {"role": "assistant", "content": "Ответ 1"},
    {"role": "user", "content": "Вопрос 2"}
  ]
}
```

Нет function calling / tool use

Модель не может вызывать внешние функции или API. Только текст → текст.

Нет загрузки файлов

API принимает только JSON. Загрузка файлов (изображения, документы) не поддерживается.

Ограничения моделей

qwen-32b-base — базовая модель

Модель **не оптимизирована для диалогов**. Она продолжает текст, а не «отвечает».

Что это значит: - Ответы могут быть не в формате «вопрос-ответ» - Модель может «уходить в сторону» от темы - Качество диалога ниже, чем у qwen-14b

Рекомендация: Для диалогов всегда используйте `qwen-14b`.

Контекстное окно: 4096 токенов

Обе модели имеют контекстное окно 4096 токенов (~3000–3500 слов).

При превышении: - Старые сообщения игнорируются - Модель «забывает» начало диалога

Очередь GPU на 14B

Модель `qwen-14b` использует GPU последовательно. При нескольких одновременных запросах:

- Запросы выстраиваются в очередь
- 1-й запрос: ~5 сек
- 4-й запрос: ~20 сек

- 10-й запрос: ~50 сек

Рекомендация: Делайте паузы между запросами при интенсивном использовании.

Инфраструктурные ограничения

Самоподписанный SSL-сертификат

Сертификат не от публичного CA. Требуется: - curl: `-k` (`--insecure`) - Python: `verify=False` - PowerShell: `-SkipCertificateCheck`

План: Переход на публичный сертификат запланирован к Production.

Лимит запросов: 300/мин

Превышение лимита → HTTP 429.

Лимит общий на все запросы, независимо от модели.

Отсутствие Production-мониторинга

В Beta-версии: - Нет автоматических алертов при сбоях - Нет дашбордов для пользователей - Мониторинг осуществляется командой вручную

Ограничения Beta

Максимум 5 пользователей

Closed Beta ограничена 5 участниками. Расширение — после перехода к Production.

Возможны сбои

Это Beta-версия. Возможны: - Кратковременные перебои в доступности - Изменения в API (с уведомлением) - Непредвиденное поведение моделей

Нет SLA

Время реакции на проблемы — best effort. Критические проблемы решаются в приоритетном порядке.

Что делать при обнаружении новых ограничений?

Заполните BUG REPORT. Мы учитываем все ограничения при планировании развития системы.